



### Instituto Nacional de Estadística e Informática

Escuela Nacional de Estadística e Informática





# Centro Andino de Formación y Capacitación en Estadística

Cursos Especializados en Estadística e Informática

### Estadísticos de resumen (1)

Fácilmente se pueden calcular estadísticos sumario tipo media, mediana, desviación, ...

```
> x<-rnorm(50)
> mean(x)
[1] -0.2552258
> sd(x)
[1] 1.209657
> var(x)
[1] 1.463269
> median(x)
[1] -0.3365646
#cuantiles empíricos
> quantile(x)
         0%
                    25%
                                50%
                                            75%
                                                       100%
-3.4542028 -1.1195259 -0.3365646 0.6758368 2.0094436
> pvec<-seq(0,1,0.1)
> pvec
 [1] 0.0 0.1 0.2 0.3 0.4 0.5 0.6 0.7 0.8 0.9 1.0
> quantile(x,pvec)
                     20%
                                                                                     100%
-3.4542028 -1.7757077 -1.1735237 -0.9867830 -0.6923767 -0.3365646
```

### Estadísticos de resumen (2)

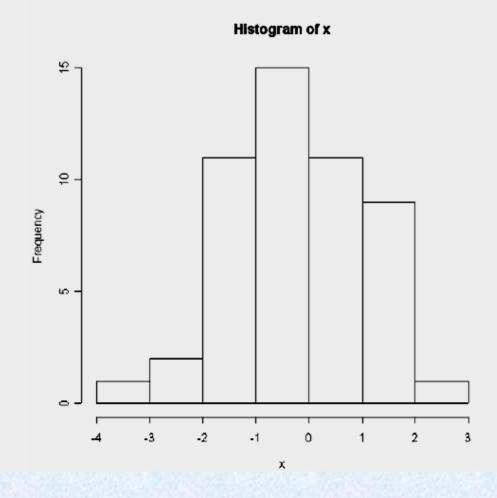
```
#exploramos el dataset juul
> library(ISwR)
> data(juul)
> ?juul
> attach(juul)
> mean(iqf1)
[1] NA
Debemos indicarle que no tenga en cuenta los valores missing:
> mean(iqf1,na.rm=T)
[1] 340.168
> sd(igf1,na.rm=T)
[1] 171.0356
#una excepción: la función length
> sum(!is.na(igf1))
[1] 1018
#directamente, función summary() sobre cualquier dataset
> summary(juul)
                                           igfl
                menarche
                                                                    testvol
Min. : 0.170 Min. : 1.000 Min. :1.000 Min. : 25.0 Min. : 1.000
                                                                  Min. : 1.000
1st Qu.: 9.053    1st Qu.: 1.000    1st Qu.:1.000    1st Qu.:202.3    1st Qu.: 1.000
                                                                  1st Qu.: 1.000
Median: 12.560 Median: 1.000 Median: 2.000 Median: 313.5 Median: 2.000
                                                                  Median : 3.000
Mean :15.095 Mean : 1.476 Mean :1.534 Mean :340.2
                                                    Mean : 2.640
                                                                  Mean : 7.896
3rd Qu.:16.855 3rd Qu.: 2.000 3rd Qu.:2.000 3rd Qu.:462.8 3rd Qu.: 5.000
                                                                  3rd Qu.: 15.000
      :83.000 Max. : 2.000
                          Max. :2.000 Max.
                                             :915.0 Max. : 5.000
                                                                  Max. : 30.000
NA's : 5.000
            NA's :635.000
                          NA's :5.000
                                       NA's
                                            :321.0
                                                        :240.000
                                                                  NA's :859.000
```

### Estadísticos de resumen (3)

```
#en el data frame tenemos variables categóricas
> detach(juul)
> juul$sex<-factor(juul$sex,labels=c("M","F"))</pre>
> juul$menarche<-factor(juul$menarche,labels=c("No","Yes"))</pre>
> juul$tanner<-factor(juul$tanner,labels=c("I","II","III","IV","V"))</pre>
> attach(juul)
> summary(juul)
     age
                 menarche
                              sex
                                            igf1
                                                        tanner
                                                                     testvol
Min.
     : 0.170
                 No :369
                              :621
                                       Min. : 25.0
                                                       I :515
                                                                  Min.
                                                                      : 1.000
1st Ou.: 9.053
                Yes :335
                              :713
                                       1st Qu.:202.3
                                                      II :103
                                                                  1st Ou.: 1.000
                                       Median :313.5
Median :12.560
                 NA's:635
                          NA's: 5
                                                       III : 72
                                                                  Median : 3.000
Mean :15.095
                                       Mean :340.2
                                                     IV : 81
                                                                  Mean : 7.896
                                       3rd Qu.:462.8
                                                     V :328
                                                                  3rd Ou.: 15.000
3rd Qu.:16.855
Max. :83.000
                                       Max.
                                              :915.0
                                                       NA's:240
                                                                         : 30.000
                                                                  Max.
NA's : 5.000
                                              :321.0
                                                                  NA's
                                                                         :859.000
                                       NA's
#también podríamos haber utilizado la función transform()
> juul<-transform(juul,
    sex=factor(sex,labels=c("M","F")),
    menarche=factor(menarche,labels=c("No","Yes")),
    tanner=factor(tanner,labels=c("I","II","III","IV","V")) )
```

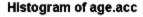
# Gráficos para una variable (1)

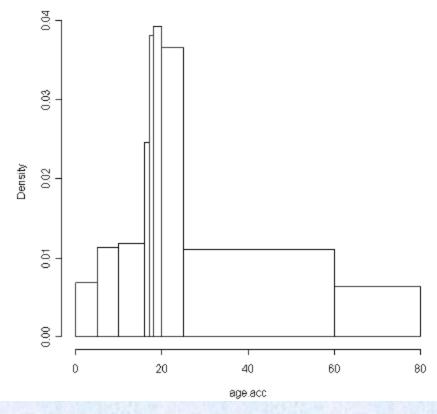
#histogramas. Por defecto R, intenta hacer puntos de corte "adecuados"
> hist(x)



### Gráficos para una variable (2)

```
#Ejemplo #accidentes vs edad (0-4,5-9,10-15,16,17,18-19,20-24,25-59,60-79)
> mid.age<-c(2.5,7.5,13,16.5,17.5,19,22.5,44.5,70.5)
> acc.count<-c(28,46,58,20,31,64,149,316,103)
> age.acc<-rep(mid.age,acc.count)
> brk<-c(0,5,10,16,17,18,20,25,60,80)
> hist(age.acc,breaks=brk)
```

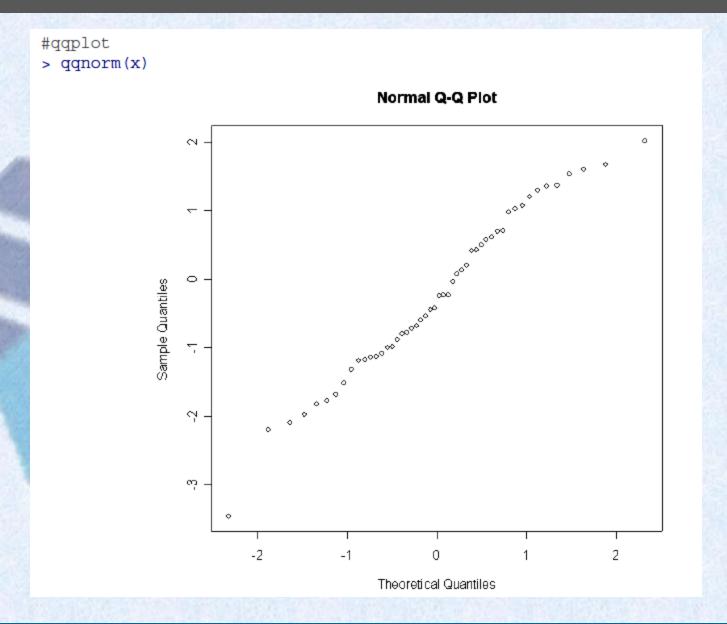




### Gráficos para una variable (3)

```
#distribución empírica acumulada
> n<-length(x)
> plot(sort(x),(1:n)/n,type="s",ylim=c(0,1))
                         8.0
                         9.0
                     (1:n)h
                         0.2
                         0.0
                                           -2
                                  -3
                                                             0
                                                     sort(x)
```

# Gráficos para una variable (4)



### Gráficos para una variable (5)

```
#Boxplots IgM ( Serum IgM in 298 children aged 6 months to 6 years)
> data(IgM)
> ?IgM
> par(mfrow=c(1,2))
> boxplot(IgM)
> boxplot(log(IgM))
> par(mfrow=c(1,1))
                              \omega
                                                            0
                              CV
                                                            Ŋ
                              0
```

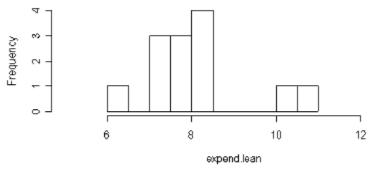
### Estadísticos de resumen para grupos (1)

```
#Folate concentration in blood cells according to three types of ventilation during
anesthesia
> data(red.cell.folate)
> attach(red.cell.folate)
> ?red.cell.folate
> summary(red.cell.folate)
    folate
                    ventilation
 Min. :206.0 N2O+O2,24h:8
 1st Qu.:249.5 N2O+O2,op :9
 Median :274.0 02,24h :5
 Mean :283.2
 3rd Ou.:305.5
 Max. :392.0
> tapply(folate, ventilation, mean)
N2O+O2,24h N2O+O2,op O2,24h
  316.6250 256.4444 278.0000
> #Para tener más de un estadístico resumen por grupo
> m<-tapply(folate,ventilation,mean)</pre>
> s<-tapply(folate, ventilation, sd)
> n<-tapply(folate, ventilation, length)</p>
> cbind(mean=m,std.dev=s,n=n)
              mean std.dev n
N2O+O2,24h 316.6250 58.71709 8
N2O+O2, op 256.4444 37.12180 9
O2,24h 278.0000 33.75648 5
```

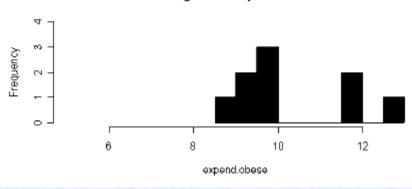
### Estadísticos de resumen para grupos (2)

# Gráficos para datos agrupados (1)

```
#cargamos el dataset energy
> data(energy)
  attach (energy)
> summary(energy)
     expend
                    stature
        : 6.130
                   lean:13
 Min.
                   obese: 9
 1st Qu.: 7.660
 Median : 8.595
        : 8.979
 Mean
 3rd Qu.: 9.900
        :12.790
 Max.
> ?energy
```



#### Histogram of expend.obese



### Gráficos para datos agrupados (2)

#boxplots para cada grupo > boxplot(expend~stature) > boxplot (expend.lean, expend.obese)  $\square$  $\circ$ 

### Gráficos para datos agrupados (3)

```
#con muestras tan pequeñas, los boxplots pueden resultar engañosos
#gráficos de los datos originales, punto a punto
> opar < -par(mfrow=c(2,2), mex=0.8, mar=c(3,3,2,1)+0.1)
> stripchart(expend~stature)
> stripchart(expend~stature,method="jitter")
> stripchart(expend~stature,method="stack")
> stripchart(expend~stature,method="stack",jitter=0.03)
> par(opar)
```

### Tablas (1)

```
#Una tabla debe estar en un objecto tipo matriz
#Ejemplo mujeres consumo cafeína vs estado civil
> caff.marital<-matrix(c(652,1537,598,242,36,46,38,21,218,327,106,67),nrow=3,byrow=T)</pre>
> caff.marital
    [,1] [,2] [,3] [,4]
[1,] 652 1537 598 242
[2,] 36 46 38 21
[3,] 218 327 106
                    67
> colnames(caff.marital)<-c("0","1-150","151-300",">300")
> rownames(caff.marital)<-c("Married", "Prev.married", "Single")</pre>
> caff.marital
               0 1-150 151-300 >300
Married
            652 1537
                          598 242
Prev.married 36 46 38 21
Single 218 327 106 67
#también podemos crearla a partir de variables categóricas de un dataset
table(sex)
 M F
621 713
> table(sex,menarche)
sex No Yes
 M 0 0
 F 369 335
> table(menarche,tanner)
menarche I II III IV V
   No 221 43 32 14 2
```

### Tablas (2)

```
#podemos transponer las tablas
> t(caff.marital)
        Married Prev.married Single
0
             652
                             36
                                   218
1-150
                                   327
          1537
                             46
          598
                                   106
151-300
                            38
       242
                            21
                                  67
>300
#para calcular las frecuencias marginales, perfiles fila, . >> prop.table(tanner.sex,1)
> tanner.sex<-table(tanner,sex)</pre>
                                                                  tanner M
> tanner.sex
                                                                        0.5650485 0.4349515
     sex
                                                                     II 0.5339806 0.4660194
tanner M
                                                                     III 0.4722222 0.5277778
      291 224
                                                                     IV 0.5061728 0.4938272
       55 48
                                                                        0.3780488 0.6219512
  III 34 38
                                                                  > prop.table(tanner.sex,1)*100
  IV 41 40
  V 124 204
                                                                  tanner M
> margin.table(tanner.sex,1)
                                                                        56.50485 43.49515
tanner
                                                                     II 53.39806 46.60194
  I II III IV
                                                                     III 47.22222 52.77778
515 103 72 81 328
                                                                     IV 50.61728 49.38272
> margin.table(tanner.sex,2)
                                                                        37.80488 62.19512
sex
                                                                  > tanner.sex/sum(tanner.sex)
                                                                        sex
545 554
                                                                  tanner M
                                                                        0.26478617 0.20382166
                                                                     II 0.05004550 0.04367607
                                                                     III 0.03093722 0.03457689
                                                                     IV 0.03730664 0.03639672
                                                                        0.11282985 0.18562329
```

# Gráficos para tablas (1)

```
#diagrama de barras
> total.caff<-margin.table(caff.marital,2)
> total.caff
      0
           1-150 151-300
                              >300
    906
            1910
                      742
                               330
> barplot(total.caff,col="white")
                        1000
                        500
                                        1-150
                                                  151-300
                                                             >300
```

### Gráficos para tablas (2)

```
#diagramas de barras para una tabla de contingencia
> par(mfrow=c(2,2))
> barplot(caff.marital,col="white")
> barplot(t(caff.marital),col="white")
> barplot(t(caff.marital),col="white",beside=T)
> barplot(prop.table(t(caff.marital),2),col="white",beside=T)
> par(mfrow=c(1,1))
                                                     R
                       혍
                       ₫
                                                     158
                       8
                                                     8
                                    151-300
                                                               Prev.married
                                1-150
                                                         Married
                                                                        Single
                                                     4.0
                       ₫
                       8
                                                     검
                                                     11
                       20
                                 Prev.married
                                                               Prev.married
                                                                        Single
                           Married
                                         Single
                                                         Married
```

### Gráficos para tablas (3)

```
#otro diagrama de barras para una tabla de contingencia
> barplot(prop.table(t(caff.marital),2),beside=T,
          legend.text=colnames(caff.marital),
          col=c("white", "grey80", "grey50", "black"))
                                                           - 1-150
                                                             151-300
                                                            >300
                    0.0
```

Single

Married

Prev.married

### Gráficos para tablas (4)

```
#diagrama de sectores para una tabla de contingencia
> opar<-par(mfrow=c(2,2),mex=0.8,mar=c(1,1,2,1))</pre>
> slices<-c("white", "grey80", "grey50", "black")
> pie(caff.marital["Married",],main="Married",col=slices)
> pie(caff.marital["Prev.married",],main="Previously married",col=slices)
> pie(caff.marital["Single",],main="Single",col=slices)
> par(opar)
                        Married
                                               Previously married
                                          1-150
               1-150
                                    >300
                               151-300
                                               151-300
                         Single
               1-150
                               151-300
```



### Comunicación constante con la Escuela del INEI

# Correo de la Escuela del INEI enei@inei.gob.pe

Área de Educación Virtual (campusvirtual@inei.gob.pe)

